UNIVERSIDAD DEL VALLE DE GUATEMALA

Trabajo de Graduación

Sección 10

PhD. Gabriel Barrientos



AGRUPAMIENTO DE MUNICIPIOS MEDIANTE ALGORITMOS DE APRENDIZAJE NO SUPERVISADO SEGÚN LA INCIDENCIA DE DOCE DELITOS EN GUATEMALA

Protocolo en modalidad de Trabajo Profesional

Michelle Angel de María Mejía Villela, 22596

Guatemala, 16 de julio de 2026

Resumen

La criminalidad constituye un fenómeno complejo cuya comprensión requiere ir más allá del análisis individual de los hechos delictivos. Aunque en Guatemala existe información pública sobre la incidencia delictiva, su presentación mediante estadísticas descriptivas dificulta la identificación de patrones territoriales y limita una comprensión integral del fenómeno criminal. Estos datos requieren procesos de integración y preparación para facilitar su aprovechamiento en estudios de análisis territorial. En este contexto, el análisis de datos representa una oportunidad para fortalecer el estudio de la criminalidad.

La presente investigación tiene como propósito identificar agrupamientos de municipios de Guatemala mediante algoritmos de agrupamiento (*clustering*) de aprendizaje no supervisado. Para ello, utiliza información pública correspondiente al período 2022–2025 sobre homicidio, asesinato, robo, robo agravado, hurto, hurto agravado, extorsión, violación, violación agravada, violación con circunstancias especiales de agravación, agresión sexual y agresión sexual con agravación de la pena, complementada con datos poblacionales oficiales. A partir de esta información, prepara los datos para facilitar su comparación entre municipios y evalúa diferentes algoritmos con el propósito de identificar agrupamientos con características delictivas similares.

Los resultados contribuyen a una comprensión territorial del fenómeno criminal y facilitan la interpretación de patrones de incidencia delictiva mediante recursos de visualización. Asimismo, la investigación evidencia el potencial del aprendizaje no supervisado como herramienta de apoyo para el análisis criminal y genera información que puede servir como base para futuras investigaciones y, probablemente, estudios de estrategias de prevención.

Palabras clave: aprendizaje no supervisado, agrupamiento, criminalidad, análisis territorial, incidencia delictiva, municipios.

Abstract

Crime is a complex phenomenon whose understanding requires going beyond the individual analysis of criminal acts. Although public information on crime incidence is available in Guatemala, its presentation through descriptive statistics makes it difficult to identify territorial patterns and limits a comprehensive understanding of the criminal phenomenon. These data require integration and preparation processes to facilitate their use in territorial analysis studies. In this context, data analysis represents an opportunity to strengthen the study of crime.

The purpose of this research is to identify clusters of municipalities in Guatemala using unsupervised machine learning clustering algorithms. To this end, it uses publicly available data for the 2022–2025 period on homicide, murder, robbery, aggravated robbery, theft, aggravated theft, extortion, rape, aggravated rape, rape under special aggravating circumstances, sexual assault, and sexual assault with an enhanced penalty, complemented by official population data. Based on this information, the study develops comparable crime incidence indicators across municipalities and evaluates different algorithms to identify groups with similar crime patterns.

The results contribute to a territorial understanding of the criminal phenomenon and facilitate the interpretation of crime incidence patterns through visualization resources. Furthermore, the research demonstrates the potential of unsupervised machine learning as a supporting tool for crime analysis and generates information that may serve as a basis for future research and, maybe, studies on prevention strategies.

Keywords: unsupervised machine learning, clustering, crime, territorial analysis, crime incidence, municipalities.

1. Introducción

El análisis de datos ha adquirido un papel fundamental en la comprensión de fenómenos complejos, permitiendo identificar patrones y relaciones dentro de grandes volúmenes de información que no siempre son evidentes mediante métodos tradicionales [1], [2]. En el ámbito de la criminalidad, el uso de técnicas computacionales ha permitido estudiar tendencias espaciales y temporales del delito, facilitando la interpretación de factores territoriales asociados a distintos tipos de incidencia criminal [3].

En Guatemala, diversas instituciones públicas generan datos relacionados con la incidencia criminal, como el Instituto Nacional de Estadística (INE), la Policía Nacional Civil (PNC) y el Ministerio Público (MP); sin embargo, estos datos suelen presentarse de forma agregada o descriptiva, lo que dificulta la identificación de patrones territoriales que permitan comprender similitudes y diferencias entre regiones [4], [5]. La aplicación de técnicas de análisis de datos representa una oportunidad para transformar esta información en conocimiento útil que permita analizar tendencias y comportamientos territoriales de forma sistemática, apoyando la comprensión del fenómeno criminal [1], [3].

Dentro del campo de la ciencia de datos, los métodos de aprendizaje no supervisado permiten descubrir estructuras latentes en conjuntos de datos sin necesidad de variables objetivo previamente definidas [2]. La segmentación de datos mediante agrupaciones de observaciones con características similares permite facilitar la identificación de patrones relevantes en distintos contextos [6]. Estas técnicas han sido aplicadas en múltiples áreas donde se busca identificar similitudes entre entidades con base en características compartidas, permitiendo generar conocimiento a partir de datos no etiquetados.

Diversos estudios han demostrado que las técnicas de agrupamiento pueden aplicarse en el análisis de criminalidad para identificar patrones y agrupar regiones con comportamientos similares en relación con la incidencia delictiva [7], [8]. El uso de métodos de minería de datos en el estudio del crimen permite analizar tendencias históricas, identificar similitudes entre zonas geográficas y facilitar la interpretación de información compleja mediante enfoques cuantitativos [3]. Estos enfoques contribuyen a complementar los métodos tradicionales de análisis, proporcionando herramientas adicionales para explorar los datos desde una perspectiva estructurada, conjunta y basada en evidencia.

El presente trabajo compara el desempeño de tres algoritmos de agrupamiento mediante métricas de validación de *clustering*, utilizando información pública correspondiente a la incidencia de doce delitos y variables demográficas a nivel municipal

en Guatemala para el período 2022–2025. A partir de la preparación y transformación de los datos, se obtiene una representación comparable entre municipios que sirve como base para la generación de agrupamientos con características delictivas similares. Posteriormente, el algoritmo seleccionado permite identificar dichos agrupamientos y apoyar el análisis de patrones territoriales.

Los resultados se representan mediante un mapa coroplético que facilita la visualización de los agrupamientos identificados y favorece la interpretación de patrones territoriales. Asimismo, el estudio evidencia el potencial del aprendizaje no supervisado como herramienta para el análisis de datos públicos y fenómenos criminales.

2. Objetivos

3. 1. Objetivo General:

Identificar agrupamientos de municipios de Guatemala mediante algoritmos de aprendizaje no supervisado, según la incidencia de doce delitos correspondientes al período 2022–2025.

3. 2. Objetivos Específicos:

1. Comparar el desempeño de tres algoritmos de agrupamiento mediante métricas de evaluación, para su uso posterior.

2. Agrupar los municipios de Guatemala en conglomerados con características delictivas similares, según doce delitos, mediante el algoritmo de agrupamiento seleccionado.

3. Caracterizar cada conglomerado según los patrones predominantes y representarlos visualmente mediante un mapa coroplético.

3. Justificación

La criminalidad es una de las problemáticas sociales complejas con mayor impacto negativo en la población, afectando directamente la seguridad, el desarrollo social y la calidad de vida [9]. En múltiples ocasiones, ciudadanos se ven expuestos a hechos delictivos debido al desconocimiento de contextos territoriales asociados a determinados patrones de criminalidad, especialmente en áreas con alta incidencia o comportamientos delictivos recurrentes [9]. A pesar de ello, gran parte de la información relacionada con criminalidad suele analizarse de manera individual, en lugar de abordar el fenómeno desde una perspectiva contextual y territorial. La comprensión de este fenómeno requiere cada vez más del uso de herramientas analíticas capaces de procesar grandes volúmenes de información y transformar datos en conocimiento útil para el análisis y la toma de decisiones [1], [3].

Diversos autores han demostrado el potencial de los algoritmos de agrupamiento para identificar agrupaciones y patrones dentro de conjuntos de datos complejos, incluyendo información relacionada con criminalidad [6], [7], [8]. A través de la agrupación y posterior caracterización de municipios con comportamientos delictivos similares, el presente proyecto busca generar conocimiento que contribuya a una mejor comprensión de las dinámicas territoriales de la criminalidad. Los resultados facilitan la comunicación de hallazgos mediante herramientas visuales accesibles y proporcionan información de interés para autoridades competentes, investigadores y población en general. Asimismo, el estudio evidencia la utilidad del aprendizaje no supervisado como alternativa metodológica para el análisis de datos públicos aplicados a problemas de relevancia social [3], [7].

4. Indicación de la modalidad

El presente trabajo se desarrolla bajo la modalidad de Trabajo Profesional.

5. Metodología

La presente sección describe la metodología utilizada para el agrupamiento de los municipios de Guatemala mediante algoritmos de aprendizaje no supervisado según la incidencia de doce delitos. Asimismo, presenta la comparación de las métricas de agrupamiento empleadas para seleccionar el modelo con el mejor desempeño entre los tres algoritmos evaluados.

5.1. Recolección de datos

Los datos correspondientes a la incidencia de doce delitos se obtienen mediante una solicitud de acceso a la información pública presentada al Ministerio Público de Guatemala, conforme a los mecanismos establecidos por dicha institución. Los datos demográficos por municipio se obtienen de las publicaciones oficiales del Instituto Nacional de Estadística (INE), utilizadas para complementar la información del estudio [4].

5.2. Exploración inicial

Se realiza un análisis exploratorio para comprender la estructura de los datos, identificar valores atípicos, inconsistencias y evaluar la completitud de la información por municipio y período.

5.3. Preparación y procesamiento de los datos

Los datos son sometidos a un proceso de preparación y preprocesamiento que incluye actividades como la identificación y tratamiento de valores faltantes, la eliminación de registros duplicados y la aplicación de las transformaciones que resulten necesarias para facilitar su análisis y comparación entre municipios. Dependiendo de los resultados

obtenidos durante la etapa metodológica, se evaluarán diferentes estrategias de transformación y escalamiento de los datos con el fin de determinar la representación más adecuada para el proceso de agrupamiento.

5.4. Estructuración del conjunto de datos

Se consolida un único conjunto de datos en el que cada observación corresponde a un municipio y las variables representan la información delictiva y demográfica utilizada en el estudio. Posteriormente, se evalúa si la aplicación de técnicas de transformación o reducción de dimensionalidad resulta conveniente para mejorar la representación de los datos y favorecer el proceso de agrupamiento.

5.5. Implementación y optimización de modelos

Se implementan tres modelos de aprendizaje no supervisado basados en técnicas de agrupamiento. Para cada modelo se determina la configuración óptima de parámetros mediante métodos de evaluación.

5.6. Evaluación y selección del modelo

Los modelos se evalúan mediante métricas de validación de agrupamiento, seleccionando aquel que presente la mejor calidad de agrupamiento en términos de cohesión y separación entre conglomerados.

5.7. Interpretación de conglomerados

Se caracteriza cada agrupamiento identificando los patrones predominantes que definen su perfil territorial.

5.8 . Visualización geoespacial

Como etapa final, se genera un mapa coroplético de los municipios de Guatemala, coloreado según el agrupamiento asignado a cada uno. Esta visualización permite representar la distribución espacial de los agrupamientos y analizar su comportamiento territorial, identificando posibles patrones de agrupación, concentración o dispersión entre municipios. Los resultados obtenidos facilitan la interpretación de la distribución geográfica de los agrupamientos y complementan el análisis realizado mediante los algoritmos de aprendizaje no supervisado.

6. Bibliografía

[1] J. Han, M. Kamber, and J. Pei, Data Mining: Concepts and Techniques, 3rd ed.

San Francisco, CA, USA: Morgan Kaufmann, 2012.

[2] T. Hastie, R. Tibshirani, and J. Friedman, The Elements of Statistical Learning.

New York, NY, USA: Springer, 2009.

[3] F. Y. Wang, “Data mining for crime analysis,”

IEEE Intelligent Systems, vol. 18, no. 3, pp. 2–4, 2003.

[4] Instituto Nacional de Estadística, “Estadísticas sociales y demográficas de Guatemala,” Guatemala, 2024.

[5] Ministerio Público de Guatemala, “Datos abiertos y estadísticas institucionales,” Guatemala, 2024.

[6] J. MacQueen, “Some methods for classification and analysis of multivariate observations,” in Proc. 5th Berkeley Symp. Mathematical Statistics and Probability, Berkeley, CA, USA, 1967, pp. 281–297.

[7] M. S. Rony, S. C. Bakchy, and H. Rahman, “Crime Detection Using Data Mining Techniques,” Computer Science & Engineering: An International Journal (CSEIJ), vol. 10, no. 5, pp. 1–5, Oct. 2020, doi: 10.5121/cseij.2020.10501.

[8] S. Agarwal, M. Kumar, and M. Sharma, “Crime analysis using K-means clustering,”

International Journal of Computer Applications, vol. 83, no. 4, 2013.

[9] R. F. Hanson, G. K. Sawyer, A. M. Begle and G. S. Hubel, “The Impact of Crime Victimization on Quality of Life,” Journal of Traumatic Stress, vol. 23, no. 2, pp. 189–197, Apr. 2010, doi: 10.1002/jts.20508.

[10] G. Jiménez-García, "Hacia una tipología de lugares peligrosos. Caso de estudio de la comuna 11 de Dosquebradas, Colombia," Revista Criminalidad, vol. 56, no. 1, pp. 133-156, ene.-abr. 2014

[11] Ministerio de Gobernación de Guatemala, “Infografía Análisis de Seguridad Ciudadana 2019,” Guatemala, 2019. [Online]. Available: https://mingob.gob.gt/wp-content/uploads/2021/02/Infografi%CC%81a-Ana%CC%81lisis-de-Seguridad-Ciudadana-2019.pdf

[12] Congreso de la República de Guatemala, Código Penal, Decreto No. 17-73, Guatemala, 1973

7. Plan de trabajo



7. Índice preliminar

- Título
- Dedicatoria
- Agradecimientos
- Resumen
- Tabla de contenido
- Lista de figuras
- Lista de tablas
- Glosario
- Introducción
- Justificación
- Objetivos
    - Objetivo general
    - Objetivos específicos
- Marco teórico
- Metodología
- Resultados
- Discusión de resultados
- Conclusiones
- Recomendaciones
- Bibliografía
- Anexos